Mini Project: Dự báo nhu cầu và mô phỏng chính sách tồn kho

Sales Forecasting and Inventory Optimization

Họ và tên: **Võ Huỳnh Quốc Thái**

Ngày 14 tháng 10 năm 2026

I. Tóm tắt dự án

Bài toán tối ưu hóa tồn kho đóng vai trò then chốt trong hoạt động vận hành của doanh nghiệp, đặc biệt là các doanh nghiệp bán lẻ, nơi việc cân đối giữa nguồn cung, nhu cầu thị trường và chi phí lưu kho có ảnh hưởng trực tiếp đến hiệu quả kinh doanh. Tuy nhiên, việc tối ưu tồn kho chỉ dựa trên dữ liệu quá khứ mà không xét đến nhu cầu trong tương lai là một thách thức lớn: tồn kho quá nhiều làm gia tăng chi phí lưu trữ, trong khi tồn kho quá ít dẫn đến mất cơ hội bán hàng và giảm doanh thu.



Nhằm giải quyết vấn đề này cũng như tìm hiểu sâu hơn về ứng dụng của AI trong chuỗi cung ứng, tôi đã xây dựng một **hệ thống dự báo nhu cầu và mô phỏng chính sách tồn kho** từ dữ liệu M5 được lấy từ hệ thống bán lẽ của Walmart. Hệ thống là sự kết hợp 2 lớp từ mô hình dự đoán LightGBM và một app giả lập và tối ưu hàng tồn kho.

Mục lục

I Tóm tắt dự án **1**

II Giới thiệu **3**
II.1 Bối cảnh bài toán . . . 3
II.2 Mục tiêu . . . 3
II.3 Dữ liệu . . . 3

III Phân tích dữ liệu khám phá (EDA) **4**
III.1 Xu hướng . . . 4
III.1.1 Theo bang . . . 4
III.1.2 Theo danh mục con . . . 4
III.2 Outliers . . . 5

IV Dự báo nhu cầu **5**
IV.1 Thiết lập bài toán dự báo . . . 5
IV.2 Feature Engineering . . . 6
IV.2.1 Đặc trưng trễ (lag) . . . 6
IV.2.2 Đặc trưng thống kê trượt (rolling) . . . 6
IV.2.3 Trung bình mở rộng (expanding) . . . 6
IV.2.4 Mã hóa theo nhóm (target encoding) . . . 7
IV.2.5 Đặc trưng đã biết trước (lịch, sự kiện, giá) . . . 7
IV.3 Detrend . . . 7
IV.3.1 Trung bình trượt . . . 7
IV.3.2 Trend tuyến tính của LazyProphet . . . 8
IV.4 Kết quả dự báo . . . 8
IV.5 Nhận xét về dự báo . . . 8
IV.6 Nhận xét về dự báo . . . 8

V Tối ưu chi phí tồn kho **9**
V.1 Hàm chi phí . . . 9
V.2 Các tham số giả định . . . 9
V.3 Các chính sách thử nghiệm . . . 9
V.3.1 Chính sách 1: dữ liệu lịch sử . . . 10
V.3.2 Chính sách 2: dự báo . . . 10
V.3.3 Chính sách 3: dự báo có hệ số, tối ưu lưới . . . 10
V.4 So sánh kết quả chính sách . . . 11

VI Thảo luận **12**

VII Kết luận và hướng phát triển **13**

VIII Tài liệu tham khảo **13**

II. Giới thiệu

II.1 Bối cảnh bài toán

Trong bài toán quản trị tồn kho, hai quyết định quan trọng là **điểm đặt hàng lại (Reorder Point – ROP)** và **lượng hàng đặt mỗi lần (Reorder Quantity – ROQ)**. Tuy nhiên, việc xác định hai giá trị này chỉ dựa trên các thống kê lịch sử như nhu cầu trung bình có thể chưa phản ánh đầy đủ những biến động trong tương lai. Điều này có thể dẫn đến tình trạng dư thừa hàng hóa, làm tăng chi phí lưu kho, hoặc thiếu hàng, gây mất doanh thu và giảm khả năng đáp ứng nhu cầu khách hàng.

Với sự phát triển của học máy, các mô hình như LightGBM cho thấy tiềm năng trong việc khai thác dữ liệu bán lẻ dạng bảng để dự báo nhu cầu dựa trên các đặc điểm lịch sử và những yếu tố liên quan. Kết hợp kết quả dự báo với các phương pháp tối ưu hóa tồn kho mở ra hướng tiếp cận dựa trên dữ liệu, giúp xác định các chính sách đặt hàng phù hợp hơn nhằm cân bằng giữa tổng chi phí vận hành và mức độ phục vụ khách hàng.

II.2 Mục tiêu

Dự án có 2 mục tiêu chính:

- Xây dựng mô hình dự đoán nhu cầu từ dữ liệu lịch sử

- Dựa vào mô hình để xây dựng và so sánh các chính sách hàng tồn kho khác nhau tối ưu chi phí

Từ đó, nghiên cứu tập trung trả lời hai câu hỏi: Nhu cầu sản phẩm có thể được dự báo chính xác đến mức nào? Và liệu chính sách tồn kho dựa trên mô hình có giúp tối ưu tổng chi phí với mức phục vụ khách hàng mục tiêu hơn chính sách thông thường hay không?

II.3 Dữ liệu

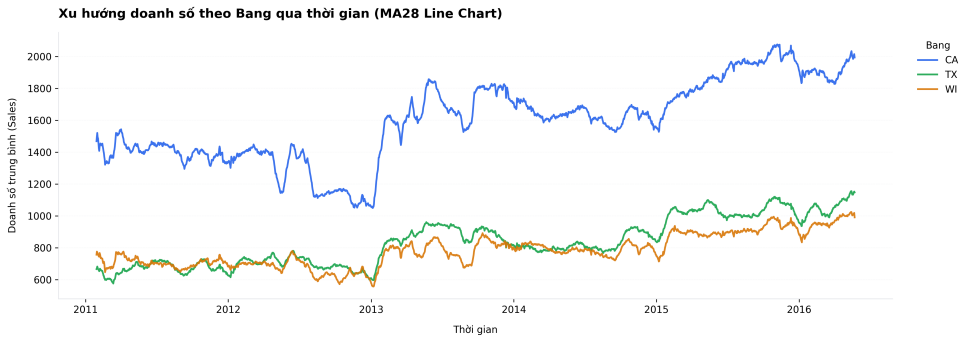
Nghiên cứu sử dụng bộ dữ liệu **M5 Forecasting**, được xây dựng từ dữ liệu bán lẻ của Walmart tại Hoa Kỳ. Bộ dữ liệu ghi nhận doanh số bán hàng hằng ngày của các sản phẩm tại 10 cửa hàng trong khoảng thời gian gần 5 năm, đồng thời cung cấp thông tin về giá bán và lịch nhằm hỗ trợ phân tích các yếu tố ảnh hưởng đến nhu cầu.

Trong phạm vi nghiên cứu, dữ liệu được giới hạn ở danh mục **HOBBIES** nhằm thu hẹp phạm vi bài toán, giảm độ phức tạp trong xử lý dữ liệu và tạo điều kiện phân tích chuyên sâu hơn về đặc điểm nhu cầu cũng như hiệu quả của các chính sách quản trị tồn kho.

III. Phân tích dữ liệu khám phá (EDA)

III.1 Xu hướng

III.1.1 Theo bang

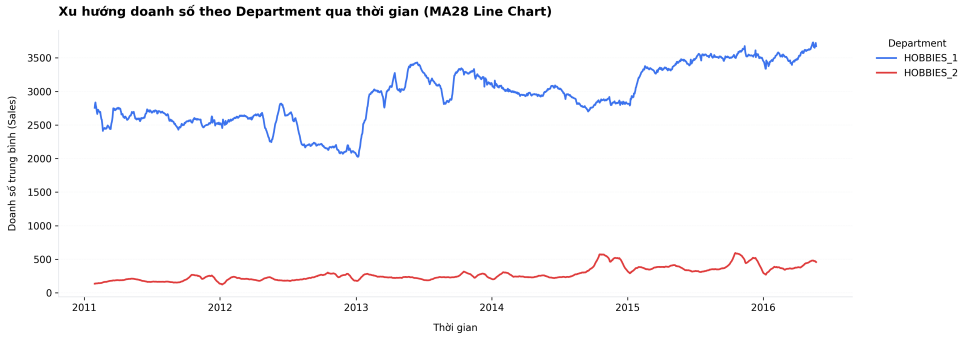


Hình 1: Biểu đồ xu hướng theo bang

Biểu đồ cho thấy doanh số tại California (CA) nhìn chung cao hơn Texas (TX) và Wisconsin (WI). Đặc biệt, doanh số tại CA giảm mạnh trong giai đoạn 2011–2013 trước khi phục hồi và tăng trở lại.

Do LightGBM không có khả năng ngoại suy xu hướng dài hạn tốt, nghiên cứu chỉ sử dụng dữ liệu từ năm 2013 trở đi để huấn luyện, đồng thời áp dụng **detrending** nhằm loại bỏ xu hướng dài hạn, giúp mô hình tập trung vào các biến động và đặc điểm mùa vụ của doanh số.

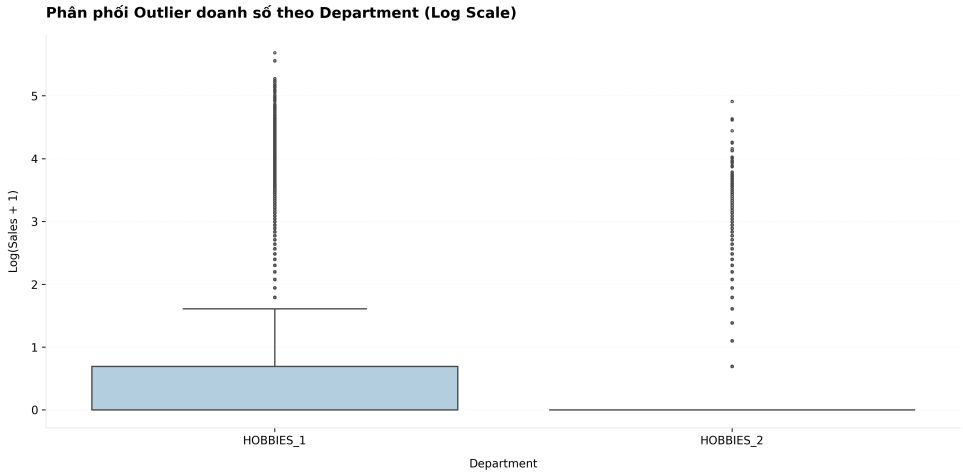
III.1.2 Theo danh mục con



Hình 2: Biểu đồ xu hướng theo danh mục con

Biểu đồ cho thấy doanh số của HOBBIES1 cao hơn đáng kể so với HOBBIES2. Bên cạnh đó, doanh số còn có sự khác biệt giữa các bang, phản ánh đặc điểm nhu cầu riêng theo từng khu vực. Vì vậy, nghiên cứu sẽ huấn luyện mô hình riêng cho từng cặp **store–department**, giúp LightGBM nắm bắt tốt hơn đặc điểm nhu cầu, xu hướng và biến động của từng nhóm sản phẩm tại mỗi cửa hàng.

III.2 Outliers



Hình 3: Biểu đồ box plot theo danh mục(log transform)

Biểu đồ cho thấy dữ liệu tồn tại nhiều outlier với độ lớn đáng kể ở cả hai nhóm HOBBIES1 và HOBBIES2. Thay vì loại bỏ các giá trị này ngay từ đầu, nghiên cứu sẽ giữ lại chúng để đánh giá khả năng học và dự báo các biến động nhu cầu bất thường của LightGBM. Hiệu quả của cách tiếp cận này sẽ được kiểm chứng thông qua kết quả trên tập kiểm tra.

IV. Dự báo nhu cầu

IV.1 Thiết lập bài toán dự báo

Bài toán là dự báo số lượng bán hằng ngày của từng chuỗi (cặp sản phẩm $\times$ cửa hàng) thuộc danh mục HOBBIES trong bộ dữ liệu M5, với chu kỳ dự báo cố định $H = 28$ ngày. Dữ liệu gồm 5.650 chuỗi (4.160 thuộc HOBBIES_1 và 1.490 thuộc HOBBIES_2) và 1.941 ngày, được đánh chỉ số $d = 1, \ldots, 1941$.

Chia tập theo thời gian. Dữ liệu được chia theo trục thời gian thay vì ngẫu nhiên, nhằm mô phỏng đúng điều kiện dự báo thực tế: mô hình chỉ được quan sát quá khứ và phải dự báo tương lai. Cụ thể, tập dữ liệu được phân thành bốn phần:

$$
\begin{aligned}
\mathcal{D}_{\text{train}} &= \{\, (i,d) : 701 \le d \le 1829 \,\}, \\
\mathcal{D}_{\text{val}}^{(1)} &= \{\, (i,d) : 1830 \le d \le 1857 \,\}, \\
\mathcal{D}_{\text{val}}^{(2)} &= \{\, (i,d) : 1858 \le d \le 1885 \,\}, \\
\mathcal{D}_{\text{val}}^{(3)} &= \{\, (i,d) : 1886 \le d \le 1913 \,\}, \\
\mathcal{D}_{\text{test}} &= \{\, (i,d) : 1914 \le d \le 1941 \,\}.
\end{aligned}
$$

Tập huấn luyện gồm 1.129 ngày. Ba cửa sổ validation liên tiếp, mỗi cửa sổ dài 28 ngày, được dùng để chọn số vòng boosting bằng early stopping. Cửa sổ test cuối cùng chỉ dùng để đánh giá và không tham gia bất kỳ quyết định huấn luyện nào.

Độ dài cửa sổ dự báo. Mỗi cửa sổ validation và test có độ dài $H = 28$ ngày. Đây là độ dài horizon của bài toán M5 gốc, nên kết quả có thể đặt cạnh các nghiên cứu khác dùng cùng giao thức.

Ràng buộc không rò rỉ thông tin. Mọi feature của ngày d chỉ được xây dựng từ các giá trị quan sát đến ngày $d - H$:

$$x_{i,d} = f\Big(\{\,\mathrm{sold}_{i,s} : s \le d - H\,\}\Big).$$

Nhờ ràng buộc này, khi dự báo cửa sổ có ngày bắt đầu a, mọi feature đều chỉ dựa trên dữ liệu đã biết tại thời điểm $a - 1$. Việc này được kiểm tra bằng assert trong pipeline: với mọi cửa sổ $[a, b]$ phải có $b - H \le a - 1$. Điều này cũng có nghĩa là dự báo được thực hiện trực tiếp cho cả 28 ngày mà không cần đệ quy, vì không có giá trị dự báo nào được đưa lại làm đầu vào.

IV.2 Feature Engineering

IV.2.1 Đặc trưng trễ (lag)

Các feature trễ là giá trị của y tại các khoảng cách được chọn trước:

$$\texttt{sold_lag_}l \;=\; y_{i,\,d-H-l}, \qquad l \in \{1, 2, 3, 6, 12, 24, 36\}.$$

Do cộng thêm H, khoảng cách thực tế là $29, 30, 31, 34, 40, 52, 64$ ngày. Tên cột giữ tiền tố `sold` vì lý do lịch sử, nhưng giá trị là của y chứ không phải của sold.

IV.2.2 Đặc trưng thống kê trượt (rolling)

Với mỗi cửa sổ $w \in \{7, 14, 30, 60, 180\}$, mô hình dùng trung bình và độ lệch chuẩn của y trên w ngày kết thúc tại $d - H$:

$$\texttt{rolling_sold_mean_}w = \frac{1}{n}\sum_{k=H}^{H+w-1} y_{i,\,d-k}, \qquad \texttt{rolling_sold_std_}w = \mathrm{sd}\left(y_{i,\,d-H-w+1}, \ldots, y_{i,\,d-H}\right),$$

với n là số giá trị quan sát được và yêu cầu tối thiểu $n \ge 2$. Cửa sổ ngắn bắt được biến động gần, cửa sổ dài mô tả mức nền ổn định. Độ lệch chuẩn cho biết chuỗi biến động mạnh đến đâu, điều quan trọng với các chuỗi thưa.

IV.2.3 Trung bình mở rộng (expanding)

Trung bình của y từ đầu chuỗi đến ngày $d - H$ đại diện cho mức bán dài hạn của chuỗi:

$$\texttt{expanding_sold_mean} = \frac{1}{n}\sum_{t \le d-H} y_{i,t}, \qquad n \ge 2.$$

IV.2.4 Mã hóa theo nhóm (target encoding)

Với mỗi nhóm G trong 12 nhóm được xác định trước (ví dụ `item_id`, `store_item`, `state_store_cat`), giá trị mã hóa là trung bình của y trong nhóm, chỉ tính trên giai đoạn huấn luyện:

$$\texttt{enc}_G(i) = \frac{1}{|\{(j,t) : g_G(j) = g_G(i),\, t \le 1829\}|} \sum_{\substack{(j,t):\, g_G(j)=g_G(i) \\ t \le 1829}} y_{j,t}.$$

Giá trị này cố định theo thời gian và được gán cho mọi ngày của chuỗi. Hai hạn chế cần ghi nhận: với dòng huấn luyện, trung bình có chứa chính nhãn của dòng đó, và giá trị không thích nghi khi mức bán thay đổi sau giai đoạn huấn luyện.

IV.2.5 Đặc trưng đã biết trước (lịch, sự kiện, giá)

Các đặc trưng này không phụ thuộc vào quan sát bán hàng, nên có thể tính cho mọi ngày kể cả trong tương lai:

- **Lịch:** `weekday` (mã tên thứ), `wday` (thứ trong tuần, 1–7), `month`, `year`.
- **Sự kiện:** `event_name_1`, `event_type_1`, `event_name_2`, `event_type_2`, được mã hóa thành số nguyên; giá trị -1 biểu thị không có sự kiện.
- **SNAP:** `snap_CA`, `snap_TX`, `snap_WI`, nhận giá trị nhị phân theo bang.
- **Giá bán:** `sell_price` của sản phẩm tại cửa hàng trong tuần tương ứng; có giá trị thiếu trước khi sản phẩm được bày bán.
- **Định danh:** `item_id` và `state_id` được đưa vào làm feature. Các mã `id`, `store_id`, `dept_id` không dùng làm feature vì là hằng số trong mỗi mô hình hoặc định danh quá chi tiết; `cat_id` là hằng số với danh mục HOBBIES nên không mang thông tin.

IV.3 Detrend

Mức nền (trend) của nhóm g được ước lượng từ mức bán trung bình theo chuỗi $\bar{s}_{g,t} = \frac{1}{|g|}\sum_{i \in g} \text{sold}_{i,t}$ rồi trừ khỏi $\text{sold}_{i,d}$ để tạo $y_{i,d}$. Tôi thử hai cách ước lượng ngay từ đầu và đánh giá cả hai trên cùng cấu hình mô hình, cùng tiêu chí early stopping và cùng các cửa sổ validation.

IV.3.1 Trung bình trượt

Mức nền là trung bình trượt W ngày của $\bar{s}_{g,t}$, lệch $H = 28$ ngày:

$$\tau^{\text{MA}}_{g,d} = \frac{1}{W} \sum_{k=1}^{W} \bar{s}_{g,\, d-H-k+1}.$$

Phương pháp này không có tham số ngoại suy, nên mức nền của mọi ngày chỉ phụ thuộc dữ liệu đã quan sát đến $d - H$.

IV.3.2 Trend tuyến tính của LazyProphet

Trend được fit bằng LazyProphet (phiên bản 0.1, `estimator = 'linear'`) chỉ trên $t \leq 1829$, không có thành phần mùa. Với ngày kiểm tra $T + k$, $T = 1829$, trend được ngoại suy theo độ dốc của hai điểm cuối:

$$\hat{\tau}_{g,T+k} = \hat{\tau}_{g,T} + k \left(\hat{\tau}_{g,T} - \hat{\tau}_{g,T-1} \right).$$

Độ dốc này nhạy với dao động cuối giai đoạn huấn luyện, nên có thể được khuếch đại thành xu hướng kéo dài qua 112 ngày.

IV.4 Kết quả dự báo

Mô hình	**RMSE**
Không detrend	0,78
Detrend LazyProphet (linear)	0,75
Mô hình đề xuất (trung bình trượt)	**0,74**

IV.5 Nhận xét về dự báo

IV.6 Nhận xét về dự báo

Mô hình nắm bắt được xu hướng và chu kỳ chung nhưng không dự báo được các đỉnh và đáy do outlier lớn, khiến dự báo mượt hơn thực tế. Sai số lớn tập trung ở đuôi phải (nhu cầu cao hơn dự báo), nên giả định phân phối chuẩn có thể đánh giá thấp rủi ro thiếu hàng.

Với tồn kho an toàn $SS = z_\alpha \, \sigma_e \sqrt{L}$, đề xuất ước lượng σ_e và phân vị α của sai số trực tiếp từ cửa sổ kiểm định thay vì từ độ biến động thực tế, vì dự báo đã nén biên độ và làm giảm độ lệch chuẩn thực tế. Nếu dự báo lệch có hệ thống ở một số nhóm, cần hiệu chỉnh trước khi tính SS.

V. Tối ưu chi phí tồn kho

V.1 Hàm chi phí

Tổng chi phí của một chính sách gồm chi phí đặt hàng, chi phí tồn kho và chi phí thiếu hàng:

$$C = K\,N_{\text{đơn}} + h\sum_t I_t + p\sum_t U_t,$$

trong đó:

- K: chi phí cố định cho mỗi đơn hàng (\$/đơn).
- $N_{\text{đơn}}$: số đơn hàng được đặt trong giai đoạn đánh giá.
- h: chi phí lưu kho cho một đơn vị hàng trong một ngày (\$/đơn vị/ngày), $h = h_a/365$.
- I_t: tồn kho cuối ngày t (đơn vị).
- p: chi phí thiếu hàng cho một đơn vị nhu cầu không được đáp ứng (\$/đơn vị), $p = v_{\text{ref}} - c$, tức lợi nhuận gộp bị mất.
- $U_t = \max(0, D_t - A_t)$: nhu cầu không được đáp ứng trong ngày t (đơn vị). Đây là mất doanh số, không chuyển sang ngày sau.
- D_t: nhu cầu thực tế trong ngày t (đơn vị).
- A_t: lượng hàng sẵn sàng bán trong ngày t (đơn vị).

Mức phục vụ được đo bằng tỉ lệ đáp ứng nhu cầu:

$$\text{FillRate} = 1 - \frac{\sum_t U_t}{\sum_t D_t},$$

trong đó $\sum_t U_t$ là tổng nhu cầu bị mất và $\sum_t D_t$ là tổng nhu cầu trong giai đoạn đánh giá.

V.2 Các tham số giả định

- **Chi phí:** v_{ref} là trung vị giá bán trong giai đoạn tối ưu; $c = 0{,}76\,v_{\text{ref}}$; $h_a = 0{,}25c$; $h = h_a/365$; $K = 5\,\$$ mỗi đơn; $p = v_{\text{ref}} - c$.
- **Vận hành:** $L = 10$ ngày; kiểm kê hằng ngày; thiếu hàng là mất doanh số; giai đoạn tối ưu là ba tháng đầu, giai đoạn kiểm tra là tháng thứ tư; mức phục vụ mục tiêu 95

Các giá trị chi phí là giả định của mô hình, không phải chi phí thực tế của Walmart.

V.3 Các chính sách thử nghiệm

Chính sách kiểm kê liên tục (s, Q) với $L = 10$ ngày. Ba chính sách được so sánh trên cùng giai đoạn và cùng ngày.

V.3.1 Chính sách 1: dữ liệu lịch sử

Tồn kho an toàn và điểm đặt hàng lại:

$$SS_1 = z\,\sigma_d\sqrt{L}, \qquad ROP_1 = \left\lceil \bar{d}L + SS_1 \right\rceil,$$

trong đó $\bar{d}$ và σ_d là trung bình và độ lệch chuẩn của nhu cầu hằng ngày trong giai đoạn tối ưu, và $z = 1{,}645$ tương ứng mức phục vụ chu kỳ 95

Lượng đặt hàng theo EOQ:

$$Q_1 = \left\lceil \sqrt{\frac{2K \cdot 365\,\bar{d}}{h_a}} \right\rceil.$$

ROP_1 và Q_1 cố định trong suốt giai đoạn đánh giá.

V.3.2 Chính sách 2: dự báo

Tại mỗi gốc T, lấy các dự báo $\hat{d}_{T+h}$ với $h = 1, \ldots, L$ và tính nhu cầu dự báo trong thời gian bổ sung:

$$\hat{D}_{10,T} = \sum_{h=1}^{10} \hat{d}_{T+h}.$$

Tồn kho an toàn được ước lượng từ sai số dự báo cuộn trên giai đoạn tối ưu, với $E_{10,t} = D_{10,t} - \hat{D}_{10,t}$:

$$SS_2 = \max\left(0,\ \text{Quantile}_{0,95}(E_{10})\right).$$

Điểm đặt hàng lại và lượng đặt hàng:

$$ROP_{2,T} = \left\lceil \hat{D}_{10,T} + SS_2 \right\rceil, \qquad Q_{2,T} = \left\lceil \sqrt{\frac{2K \cdot 365\,\hat{D}_{10,T}/10}{h_a}} \right\rceil.$$

$ROP_{2,T}$ và $Q_{2,T}$ được cập nhật mỗi ngày. Sai số không dùng dữ liệu của tháng kiểm tra.

Mô hình được huấn luyện với mọi feature trễ ít nhất 28 ngày, nên mỗi dự báo chỉ dùng dữ liệu đến T. Với $h \le 10$, dự báo không dùng 27 ngày quan sát gần nhất, nên thông tin mới được đưa vào ROP chậm hơn điều kiện thực tế.

V.3.3 Chính sách 3: dự báo có hệ số, tối ưu lưới

Hai hệ số điều chỉnh được áp dụng lên Chính sách 2:

$$ROP_{3,T} = \lceil \alpha\, ROP_{2,T} \rceil, \qquad Q_{3,T} = \max\left(1, \lceil \beta\, Q_{2,T} \rceil\right).$$

Hai hệ số được chọn bằng tìm kiếm lưới trên giai đoạn tối ưu:

$$\alpha \in \{0{,}8;\ 0{,}9;\ 1{,}0;\ 1{,}1;\ 1{,}2\}, \qquad \beta \in \{0{,}5;\ 0{,}75;\ 1{,}0;\ 1{,}25;\ 1{,}5\}.$$

Cặp (α^*, β^*) là cặp có chi phí thấp nhất trong các cặp đạt mức phục vụ tối thiểu:

$$(\alpha^*, \beta^*) = \arg\min_{\alpha,\beta} C_{\text{val}}(\alpha, \beta) \quad \text{với} \quad \text{FillRate}_{\text{val}} \geq 0{,}95.$$

Nếu α^* hoặc β^* nằm ở biên lưới, cần mở rộng lưới trước khi kết luận. Tham số được cố định trước khi chạy trên tháng thứ tư và không điều chỉnh theo kết quả kiểm tra.

V.4 So sánh kết quả chính sách

Do giới hạn về thời gian và tài nguyên tính toán, việc đánh giá không được thực hiện trên toàn bộ 5.650 chuỗi. Thay vào đó, ba tổ hợp được chọn để trải dài trên cả hai nhóm HOBBIES và ba bang (CA, TX, WI), nhằm phản ánh một phần sự khác biệt giữa các nhóm sản phẩm và khu vực. Kết quả vì vậy mang tính minh họa và chưa đại diện cho toàn bộ danh mục.

In đậm giá trị tốt nhất ở mỗi cột.

Bảng 1: So sánh ba chính sách tồn kho trên tổ hợp TX_2 × HOBBIES_2.

Chính sách	**Tổng chi phí**	**Tỷ lệ thiếu hàng**	**Tồn kho trung bình**
Chính sách hiện tại (dữ liệu lịch sử)	7,7	23,0%	40
Chính sách dự báo	6,8	**11,0%**	44
Chính sách đề xuất (dự báo + α, β)	**6,5**	11,3%	**25**

Bảng 2: So sánh ba chính sách tồn kho trên tổ hợp CA_2 × HOBBIES_1.

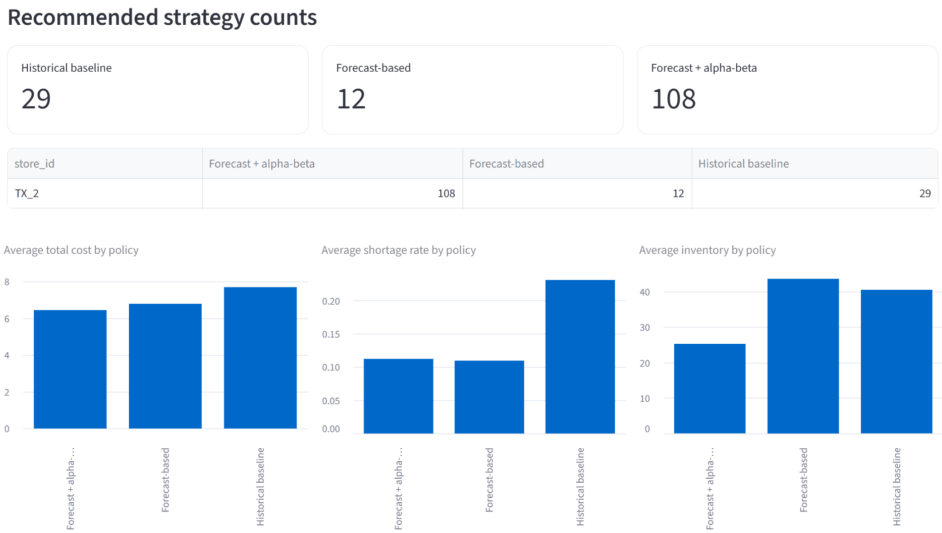
Chính sách	**Tổng chi phí**	**Tỷ lệ thiếu hàng**	**Tồn kho trung bình**
Chính sách hiện tại (dữ liệu lịch sử)	10,3	14,4%	44
Chính sách dự báo	**8,9**	**7,1%**	46
Chính sách đề xuất (dự báo + α, β)	**8,9**	7,7%	**40**

Bảng 3: So sánh ba chính sách tồn kho trên tổ hợp WI_3 × HOBBIES_2.

Chính sách	**Tổng chi phí**	**Tỷ lệ thiếu hàng**	**Tồn kho trung bình**
Chính sách hiện tại (dữ liệu lịch sử)	8,0	26,0%	31,5
Chính sách dự báo	6,4	12,8%	36
Chính sách đề xuất (dự báo + α, β)	**6,1**	**12,5%**	**21,5**

Chính sách đề xuất có tổng chi phí thấp nhất ở TX_2 × HOBBIES_2 và WI_3 × HOBBIES_2, và ngang với chính sách dự báo ở CA_2 × HOBBIES_1. Đồng thời, nó có tồn kho trung bình thấp nhất ở cả ba tổ hợp, giảm khoảng 15 đến 20 đơn vị so với chính sách dự báo thuần mà tỷ lệ thiếu hàng gần như không đổi.

Cả hai chính sách dự báo đều giảm gần một nửa tỷ lệ thiếu hàng so với chính sách dựa trên dữ liệu lịch sử ở cả ba tổ hợp. Ở CA_2 × HOBBIES_1, chính sách dự báo có thiếu hàng thấp nhất nhưng tồn kho cao hơn chính sách đề xuất, nên đây là một đánh đổi giữa mức phục vụ và lượng tồn. Tỷ lệ thiếu hàng vẫn khoảng 7 đến 13%, cao hơn mức 5% tương ứng mức phục vụ 95%, nên mục tiêu này chưa đạt trên tập kiểm tra.



Hình 4: Kết quả so sánh 3 strategy cho TX-2 x HOBBIES 2

VI. Thảo luận

Lý do kết quả như vậy. Mô hình nắm được xu hướng và chu kỳ chung nhưng không dự báo được các đỉnh và đáy riêng lẻ, nên dự báo mượt hơn thực tế. Với chính sách tồn kho, điều này khiến ROP và lượng đặt hàng không đủ để bảo vệ mức phục vụ trong các đợt tăng đột biến.

Hạn chế của dữ liệu và mô hình. Dữ liệu M5 chỉ ghi nhận số lượng bán, không phải nhu cầu thực, nên khi hàng hết, nhu cầu bị che khuất và sai số có thể bị đánh giá lạc quan. Các chuỗi HOBBIES rất thưa, khiến giả định nhu cầu xấp xỉ chuẩn trong SS_1 không hoàn toàn phù hợp. Mô hình dự báo trực tiếp với feature trễ ít nhất 28 ngày, nên với lead time 10 ngày, thông tin mới được đưa vào ROP chậm. Mức nền trung bình trượt cũng trễ khoảng 2–4 tuần khi mức bán đổi nhanh. Giai đoạn kiểm tra chỉ có một tháng, và α, β được chọn trên cùng giai đoạn tối ưu nên có nguy cơ tối ưu quá mức.

Hàm chi phí được đơn giản hóa. Hàm chi phí chỉ gồm chi phí đặt hàng, lưu kho và mất doanh số, với các giá trị giả định $K = 5\,\$$, tỉ lệ lưu kho 25%/năm và $p = v_{\text{ref}} - c$. Mất doanh số không kéo theo chi phí uy tín, không có backorder, giá bán cố định không có

khuyến mãi, hàng không có hạn sử dụng, và thời gian bổ sung cố định 10 ngày. Trong các giả định này, tỉ lệ p/h và K ảnh hưởng nhiều nhất đến cặp (α^*, β^*), nên kết luận chỉ đúng trong bộ tham số đã chọn và cần kiểm tra độ nhạy.

VII. Kết luận và hướng phát triển

Mặc dù mô hình dự báo và tối ưu còn nhiều hạn chế, kết quả bước đầu cho thấy quy trình có hiệu quả. Mô hình có thể được cải thiện bằng cách giúp nó tự nắm bắt xu hướng và các biến động, thông qua kết hợp với các mô hình học sâu. Về phần tối ưu, cần bổ sung thêm tình huống backorder để mô hình gần với thực tế hơn.

VIII. Tài liệu tham khảo

Tài liệu

[1] Trường Cao đẳng Kinh tế Đối ngoại. *Quy luật ROP và EOQ: các khái niệm cơ bản trong quản trị hàng tồn kho*. Studocu. `https://www.studocu.vn/vn/document/truong-cao-dang-kinh-te-doi-ngoai/logistics/quy-luat-rop-va-eoq-cac-khai-niem-co-ban-trong-quan-tri-hang-ton-kho/151739658`

[2] Y. In. *Yeonjun In (stu) 1st Place Solution*. Kaggle, M5 Forecasting Accuracy. `https://www.kaggle.com/competitions/m5-forecasting-accuracy/writeups/yeonjun-in-stu-1st-place-solution`

[3] K. Yakovlev. *M5 simple FE*. Kaggle. `https://www.kaggle.com/code/kyakovlev/m5-simple-fe`

[4] OpenAI. *ChatGPT*. `https://chat.openai.com`